



中山大學經濟所碩士論文口試

比較ARMA-GARCH、Prophet、LSTM模型 預測加密貨幣波動度之準確率

Compared with ARMA-GARCH, Prophet, LSTM models in predicting the accuracy of cryptocurrency volatility

指導教授：張光亮博士

口試委員：李慶男博士

張瑞娟博士

研究生：王舒右

中華民國一一二年六月十三日

比對結果

總論文	11%
第一章 緒論	8%
第二章 文獻回顧	10%
第三章 研究方法與模型介紹	9%
第四章 實證結果	5%
第五章 結論	5%



目錄

AGENDA

緒論

01

文獻回顧

02

研究方法與模型介紹

03

實證結果

04

結論

05



緒論

- 研究背景
- 研究動機
- 研究目的
- 研究架構

研究背景



金融市場 全面數位化

支付習慣改變

加密貨幣成為用於消費、
投資熱門的金融商品

截至2022/11，成交量排行：

1. 比特幣 (BTC) : \$518B
2. 以太幣 (ETH) : \$218.4B
3. 幣安幣 (BNB) : \$48B

資料來源：幣安 (Binance) 交易所

人工智慧 (AI) 技術快速進步

資料量爆炸式成長

運算力提高

演算法進步

機器學習 (ML)

深度學習 (DL)

↗ 金融領域研究

研究動機

比較三種模型在比特幣（BTC）、
以太幣（ETH）及幣安幣（BNB）
上波動度的預測能力

優

缺

ARMA-GARCH (1,1)

- 訓練時間最
快
- 靈活性高
- 建模前需對
數據進行平
穩化
- 需事前決定
落後期數
- 線性假設

Prophet

- 非線性假設
- 不需對數據進
行平穩化
- 模型訓練速度
快，且對缺失
值有容錯能力
- 解釋能力強
- 基於歷史資
料進行預
測，無法考
慮到其他變
量的影響
(例：總體
經濟數據)

RNN-LSTM

- 非線性假設
- 不需對數據進行
平穩化
- 通過輸入資料的
非線性特徵適應
資料的變化
- 預測準確度較高
- 訓練時間長
- 解釋能力低
- 需要大量的數
據

研究目的

- ARMA-GARCH (1,1)
- Prophet
- RNN-LSTM



Purpose 1

以3分鐘為區間，
預測下1期、下2期、下3期和下5期的成效
優劣。

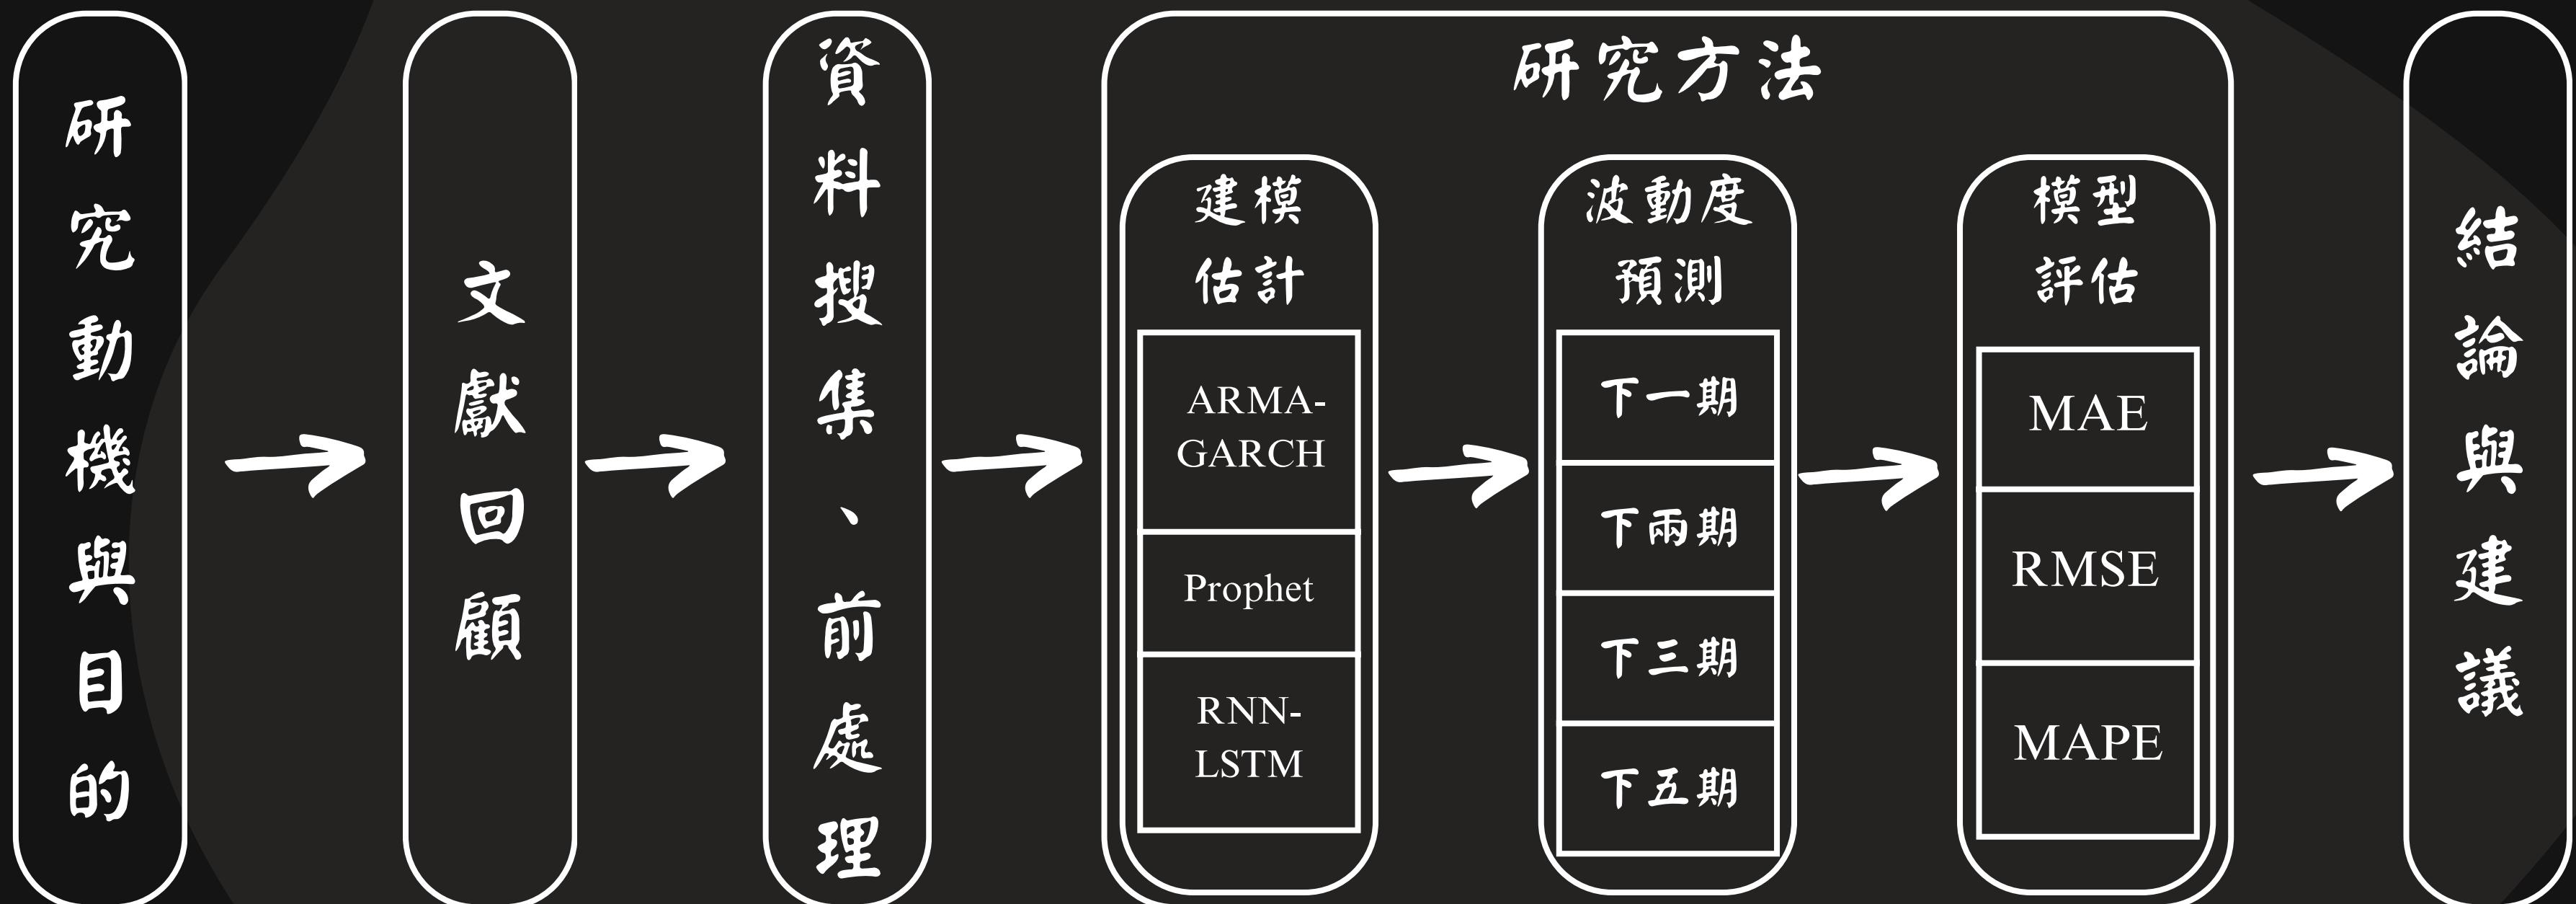
Purpose 2

以5分鐘為區間，
預測下1期、下2期、下3期和下5期的成效
優劣。

Purpose 3

以15分鐘為區間，
預測下1期、下2期、下3期和下5期的成效
優劣。

研究架構



文獻回顧

文獻回顧



Yusuf Aker (2022)

比較模型：LSTM、Prophet

預測目標：土耳其的BIST-100指數波動度

資料期間：2021-01-01 ~ 2021-12-31

比較基準：MAE、MSE、RMSE

研究結果：LSTM皆勝於Prophet

Chatterjee (2022)

比較模型：GARCH、GJR-GARCH、EGARCH、LSTM

預測目標：印度的銀行業、IT、製藥業指數每日報酬波動度

資料期間：2017-1-1 ~ 2020-12-31

比較基準：RMSE

研究結果：LSTM勝於GARCH系列模型

Shen et.al (2021)

比較模型：EWMA、ARMA (2,2) -GARCH (1,2)
、RNN-LSTM

預測目標：比特幣 (BTC) 報酬率波動度
(下一、五、十五天)

代理變數：每日平方報酬率、Garman-Klass 波動率

資料期間：2013-4-30 ~ 2021-5-21

比較基準：MAE、RMSE

研究結果：

每日平方報酬率 → RNN-LSTM 在 MAE 表現較好
但 RMSE 表現較差

Garman-Klass 波動率 → ARMA (2,2) -GARCH (1,2)
表現最好



研究方法與模型介紹

- 資料前處理
- 模型介紹
- 評估指標

資料前處理

- 實際波動度 (RV)
- 滑動窗口算法
- 單根檢定 (ADF)
- 落後期數 (Lag) 決定

實際波動度
(Realized Volatility, RV)

$$RV_t = \sqrt{\sum_{i=1}^n [\ln(P_i) - \ln(P_{i-1})]^2}$$

計算價格在一定時間內變動的程度，
衡量價格波動程度具代表性的指標

滑動窗口算法
(Sliding Window Algorithm)



1. 簡單易於理解和實現
2. 效率高
3. 適用性廣

資料前處理

- 實際波動度 (RV)
- 滑動窗口算法
- 單根檢定 (ADF)
- 落後期數 (Lag) 決定

單根檢定

(Augmented Dickey-Fuller, ADF)

$$H_0 : \delta = 0 \text{ vs. } H_1 : \delta < 0$$

$$ADF_{-t} = \frac{\hat{\delta}}{\sqrt{Var(\hat{\delta})}}$$

檢定時間序列的隨機變量在長期內
是否保持不變，不存在趨勢性

Type	ADF-Statistic	P-Value
比特幣 (BTC)	-76.1017	0.0000***
以太幣 (ETH)	-74.3572	0.0000***
幣安幣 (BNB)	-75.3072	0.0000***

***、**、*分別代表1%、5%、10%

資料前處理

- 實際波動度 (RV)
- 滑動窗口算法
- 單根檢定 (ADF)
- 落後期數 (Lag) 決定

落後期數 (Lag) 決定

$$AIC = -2 \ln(L) + 2k$$

- L代表概似函數 (Likelihood function)
- k代表參數數量

Engle and Yoo (1987)

提出用AIC準則來決定最適落後項表現較佳

AIC	比特幣 (BTC)	以太幣 (ETH)	幣安幣 (BNB)
ARMA (0,1) - GARCH (1,1)	-4667.0678	-4089.6986	-3447.1975
ARMA (1,0) - GARCH (1,1)	-4667.0654	-4089.6961	-3447.4836
ARMA (1,1) - GARCH (1,1)	-4664.9524	-4087.6978	-3446.2421

BTC、ETH → ARMA (0,1) -GARCH (1,1)
BNB → ARMA (1,0) -GARCH (1,1)

- ARMA(m,n)-GARCH(1,1)
- Prophet
- RNN-LSTM

ARMA(m,n) -GARCH(1,1)

在描述時間序列的波動性以外，額外考慮到長期趨勢、自相關性、異質變異數等因素

$$y_t = C + \sum_{i=1}^m \phi_i y_{t-i} + \sum_{j=1}^n \theta_j \varepsilon_{t-j}$$

$$u_t = \sigma_t \varepsilon_t$$

$$\sigma_t^2 = \alpha_0 + \alpha u_{t-1}^2 + \beta \sigma_{t-1}^2$$

$$\sigma_t \sim i.i.d.(0, 1)$$

- ARMA(m,n)-GARCH(1,1)
- Prophet
- RNN-LSTM

$$\overline{RV}_t = g(t) + s(t) + h(t) + \epsilon_t$$

Prophet

Sean J. Taylor & Benjamin Letham (2017)

整合多個時間序列預測的線性與非線性模型。易於分解並根據需要增加成分項，具有很高的靈活性及可解釋性

- $g(t)$ ：趨勢項 (trend)，表示非週期性的變化趨勢
- $s(t)$ ：週期項 (seasonality)，表示週期性變化 (如：每周/每年的季節性)
- $h(t)$ ：節日項 (holiday)，表示節日所產生的固定效應
- ϵ_t ：誤差項 (error)，表示異常變動

$$\overline{RV}_t = g(t) + s(t) + h(t) + \epsilon_t$$

趨勢項 $g(t)$

$$g(t) = (k + \alpha(t)^T \delta)t + (m + \alpha(t)^T \gamma)$$

曲線的走勢在經過特定期間或存在某種潛在的週期現象後會發生變化。代表在每個子區間內函數都是線性，但在整條區間時則並不完全是線性。

稱為分段線性成長 (piecewise linear growth)

- k 代表成長率 (Growth rate)
- δ 代表成長率的調整項 (Change in rate)
- m 代表抵銷參數 (Offset parameter)
- γ 代表抵銷參數的調整項。

$$\overline{RV}_t = g(t) + s(t) + h(t) + \epsilon_t$$

週期項 $s(t)$

以矩陣呈現：

$$X(t) = [\cos\left(\frac{2\pi 1t}{P}\right), \dots, \sin\left(\frac{2\pi Nt}{P}\right)]$$

$$s(t) = X(t) \beta$$

使用傅立葉級數來呈現季節性的變化

$$\overline{RV}_t = g(t) + s(t) + h(t) + \epsilon_t$$

節曰項 $h(t)$

$$h(t) = Z(t)\kappa$$

假設特定節曰（以臺灣為例：農曆春節、中秋節等）對於時間序列的影響，提供了某種程度上可預期的衝擊，通常每年都相似，並且不會遵循其他週期的模式。

$$Z(t) = [1(t \in D_1), \dots, 1(t \in D_L)]$$

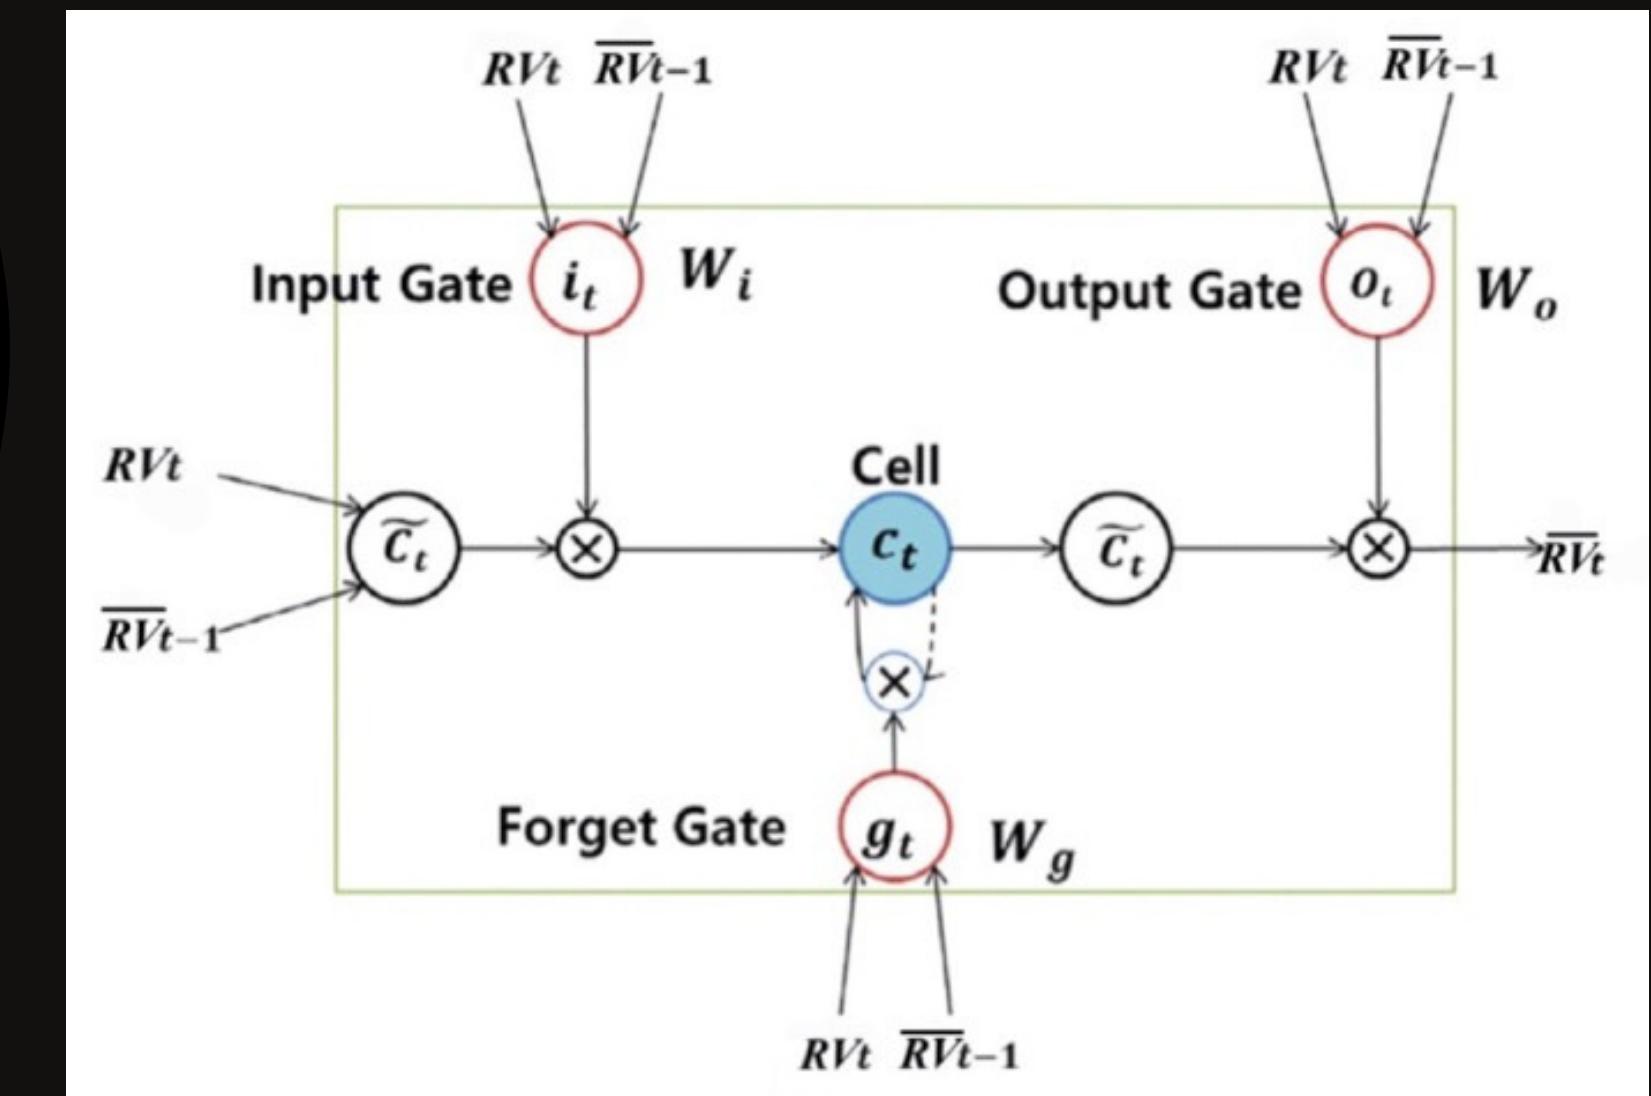
- 每個節曰*i*皆為獨立影響， $Z(t)$ 為受影響期間的集合
- κ 代表節曰的影響程度，且符合常態分佈

- ARMA(m,n)-GARCH(1,1)
- Prophet
- RNN-LSTM

RNN-LSTM

Hochreiter, Sepp & Schmidhuber, Jürgen(1997)

區分為長期記憶單元（cell state）及短期記憶單元（hidden state）並通過使用輸入門（input gate）、遺忘門（forget gate）和輸出門（output gate）管理訊息，從而提高神經網絡的長期記憶能力。



本圖參考Kim, H. Y., & Won, C. H. (2018). Forecasting the volatility of stock price index: A hybrid model integrating LSTM with multiple GARCH-type models. *Expert Systems with Applications*, 103, 25-37.

記憶單元 (memory cell)

將運算出的數值記憶起來，分成長短期記憶以利下個單元 (cell) 運用

長期記憶 (cell state)

$$C_t = g_t * C_{t-1} + i_t * \tilde{C}_t$$

- g_t 代表遺忘門 (forget gate)
- i_t 代表輸入門 (input gate)

短期記憶 (hidden state) ;
又稱輸出值

$$\overline{RV}_t = o_t * \tanh(C_t)$$

- o_t 代表輸出門 (output gate)



輸入門 (input gate)

當新一期的資料 (RV_t) 輸入時，可以控制是否將這次的值輸入

$$i_t = \text{sigmoid}(U_i RV_t + W_i RV_{t-1} + b_i)$$

- U_i 、 W_i 分別代表輸入門的權重矩陣 (weight matrix)
- b_i 代表輸入門的偏誤項 (bias)

遺忘門 (forget gate)

控制在 t 期時更新前一期記憶單位 (C_{t-1}) 的訊息

$$g_t = \text{sigmoid}(U_g RV_t + W_g RV_{t-1} + b_g)$$

$$\tilde{C}_t = \tanh(U_c RV_t + W_c RV_{t-1} + b_c)$$

- U_g 、 U_c 、 W_g 、 W_c 分別代表遺忘門的權重矩陣 (weight matrix)
- b_g 、 b_c 分別代表遺忘門的偏誤項 (bias)

輸出門 (output gate)

控制是否將這次計算出來的值 output，若無此次輸出則為 0

$$o_t = \text{sigmoid}(U_o RV_t + W_o RV_{t-1} + b_o)$$

- U_o 、 W_o 分別代表輸出門的權重矩陣 (weight matrix)
- b_o 表示輸出門的偏誤項 (bias)

模型評估指標



確定模型對樣本外資料的預測效果，以及是否能夠解決目前面臨的問題。

平均絕對誤差

$$\text{MAE} = \frac{1}{n} \sum_{t=1}^n |y_t - \bar{y}_t|$$

均方根誤差

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{t=1}^n (y_t - \bar{y}_t)^2}$$

平均絕對
百分比誤差

$$\text{MAPE} = \frac{1}{n} \sum_{t=1}^n \left| \frac{y_t - \bar{y}_t}{y_t} \right|$$

實證結果

- 資料來源
- ARMA-GARCH(1,1)
- Prophet
- RNN-LSTM



比特幣 (BTC)、以太幣 (ETH)

資料期間：2017/08/18 ~ 2022/11/27

日內區間：3分鐘、5分鐘和15分鐘

資料筆數：919,372筆、552,818筆及184,474筆

樣本內資料：2017/08/18 ~ 2021/04/27 (1349個交易日)

樣本外資料：2021/04/28 ~ 2022/11/27 (549個交易日)

幣安幣 (BNB)

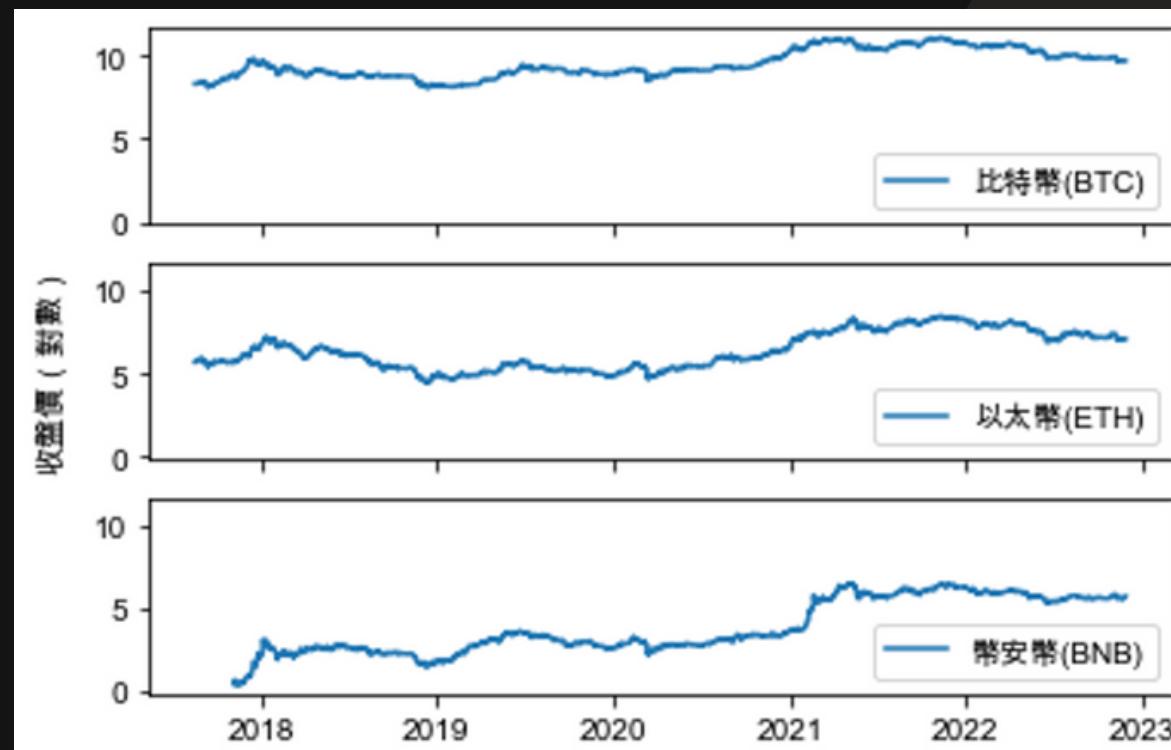
資料期間：2017/11/06 ~ 2022/11/27

日內區間：3分鐘、5分鐘和15分鐘

資料筆數：879,952筆、529,153筆及176,783筆

樣本內資料：2017/11/06 ~ 2021/05/21 (1293個交易日)

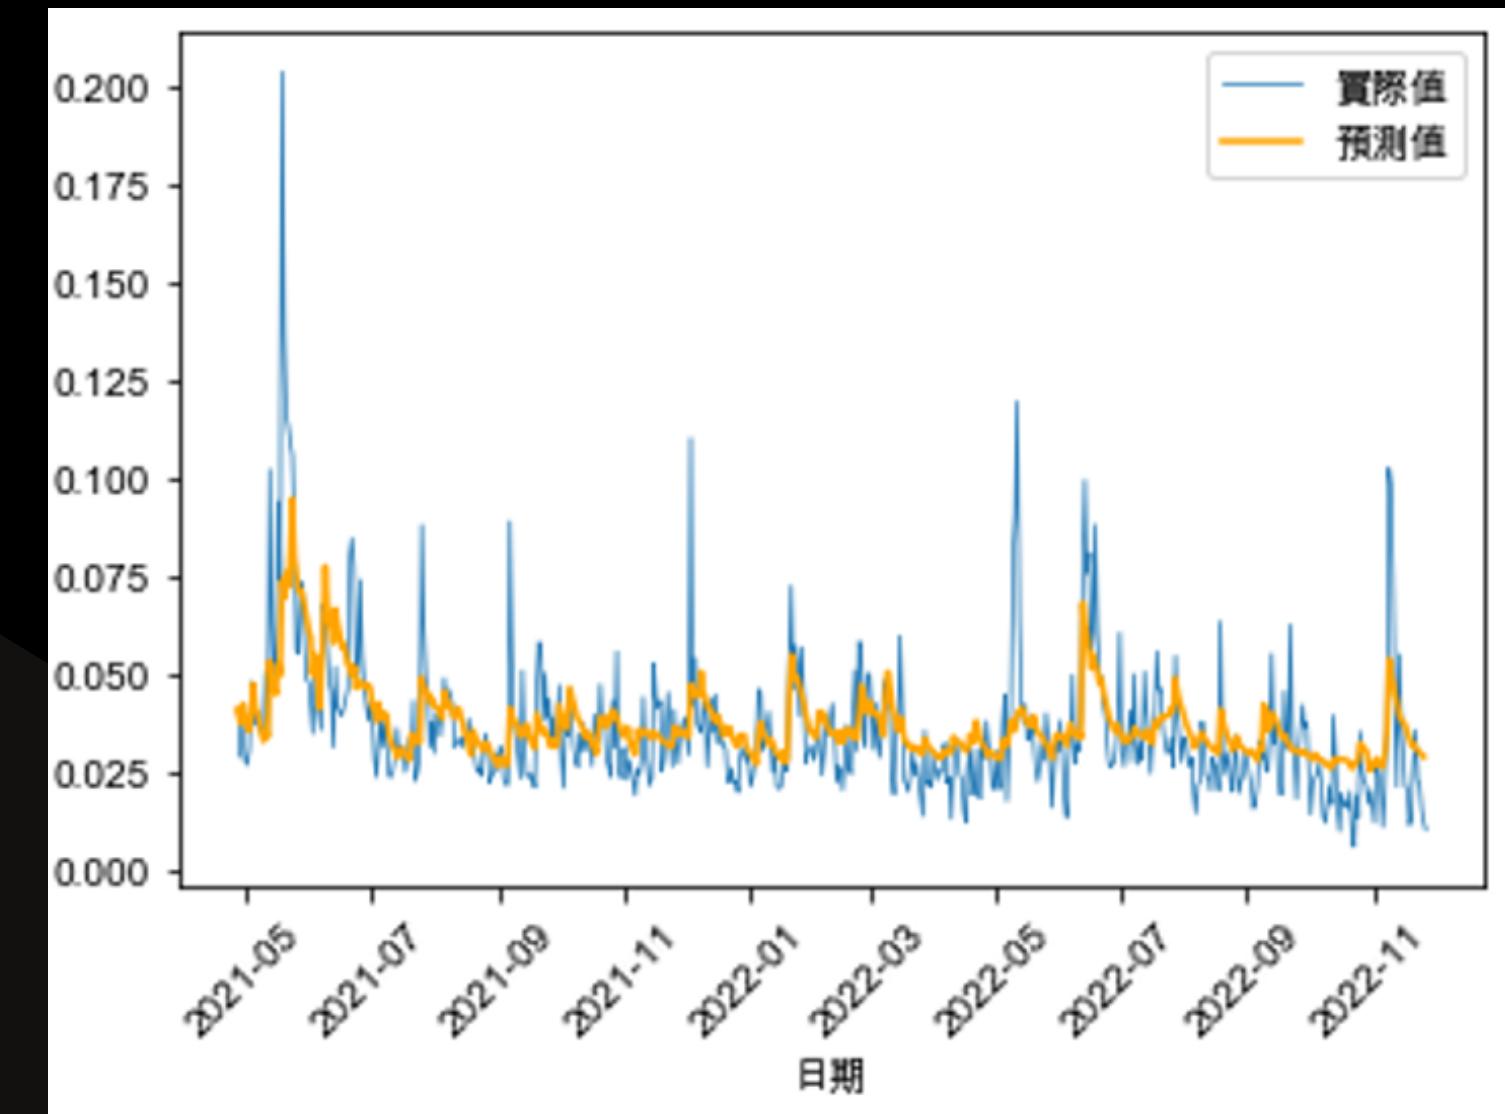
樣本外資料：2021/05/22 ~ 2022/11/27 (555個交易日)



比特幣 (BTC)
3分鐘為區間
下一期 (t+1) 預測

$$y_t = 0.0019 - 0.0086 \varepsilon_{t-1}$$

$$\sigma_t^2 = 4.3290 * 10^{-5} + 0.1000 u_{t-1}^2 + 0.8800 \sigma_{t-1}^2$$

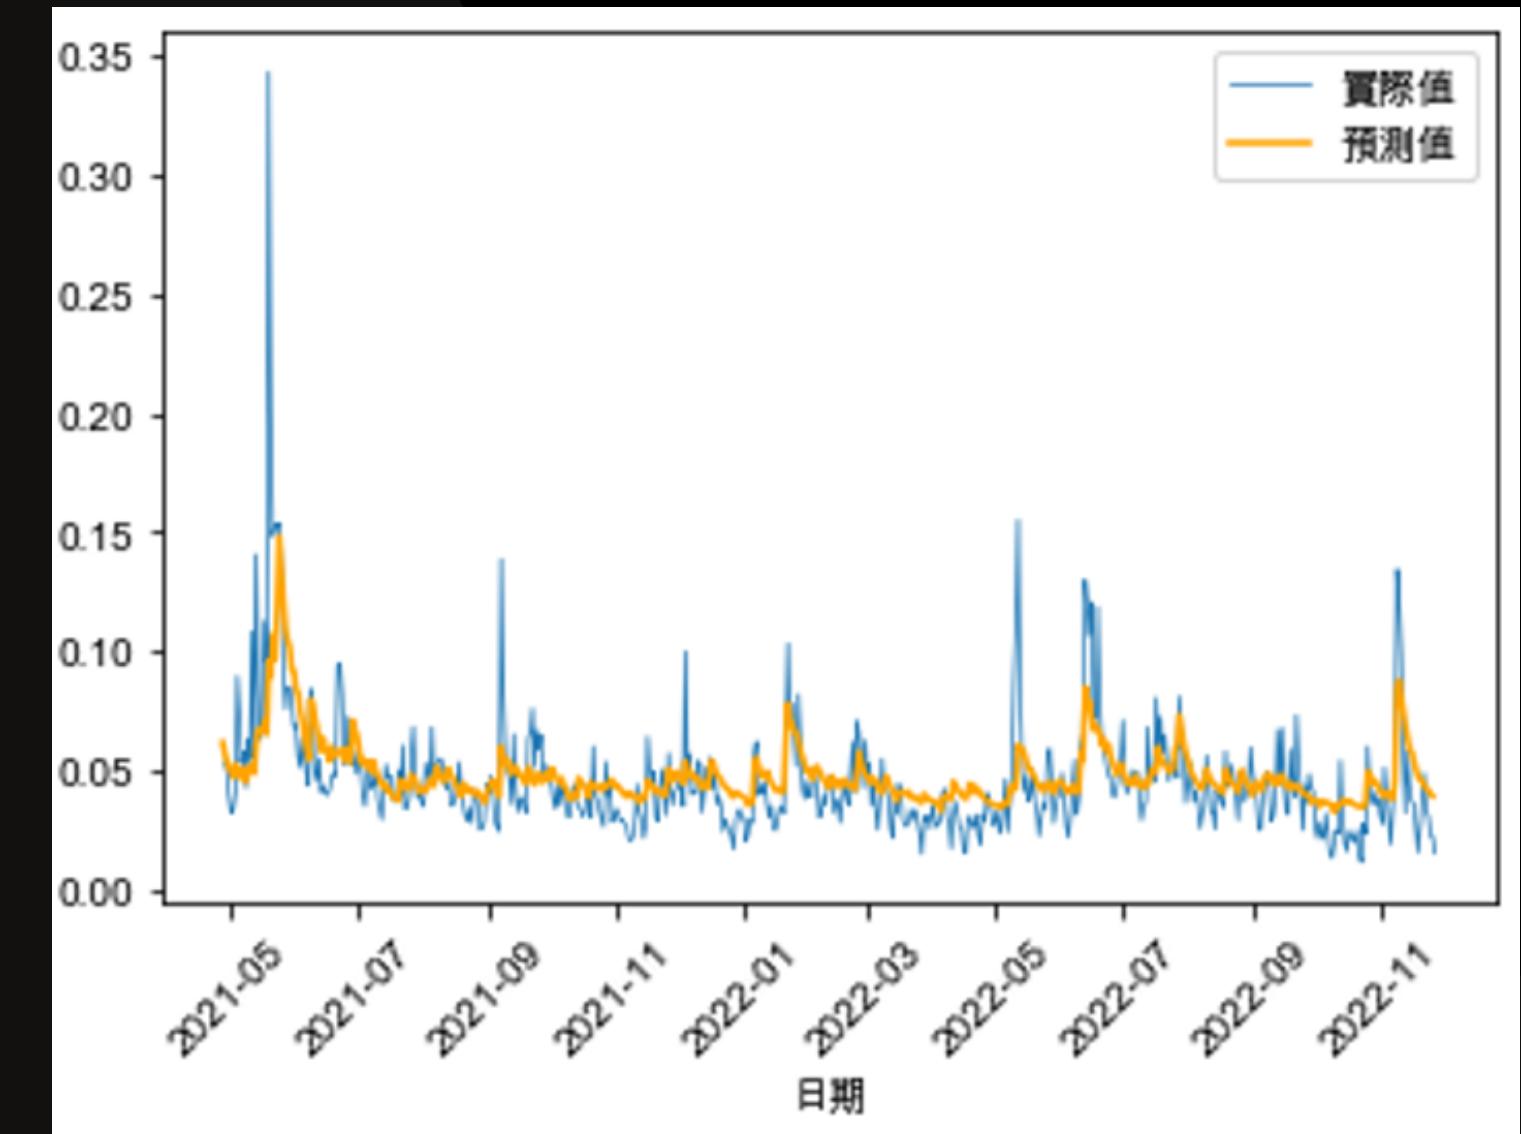


BTC		T+1	T+2	T+3	T+5
ARMA-GARCH_3min	MAE	0.0101	0.0109	0.0113	0.0119
	RMSE	0.3714	0.3976	0.4120	0.4249
	MAPE	31.6999	34.0795	35.5684	37.4741
ARMA-GARCH_5min	MAE	0.0105	0.0113	0.0118	0.0123
	RMSE	0.4056	0.4300	0.4449	0.4571
	MAPE	32.6351	35.1305	36.5063	38.3777
ARMA-GARCH_15min	MAE	0.011	0.012	0.012	0.012
	RMSE	0.370	0.396	0.409	0.422
	MAPE	36.824	39.456	40.800	42.613

以太幣 (ETH)
3分鐘為區間
下一期 (t+1) 預測

$$y_t = 0.0016 - 0.0081 \varepsilon_{t-1}$$

$$\sigma_t^2 = 1.6443 * 10^{-4} + 0.1358 u_{t-1}^2 + 0.8092 \sigma_{t-1}^2$$

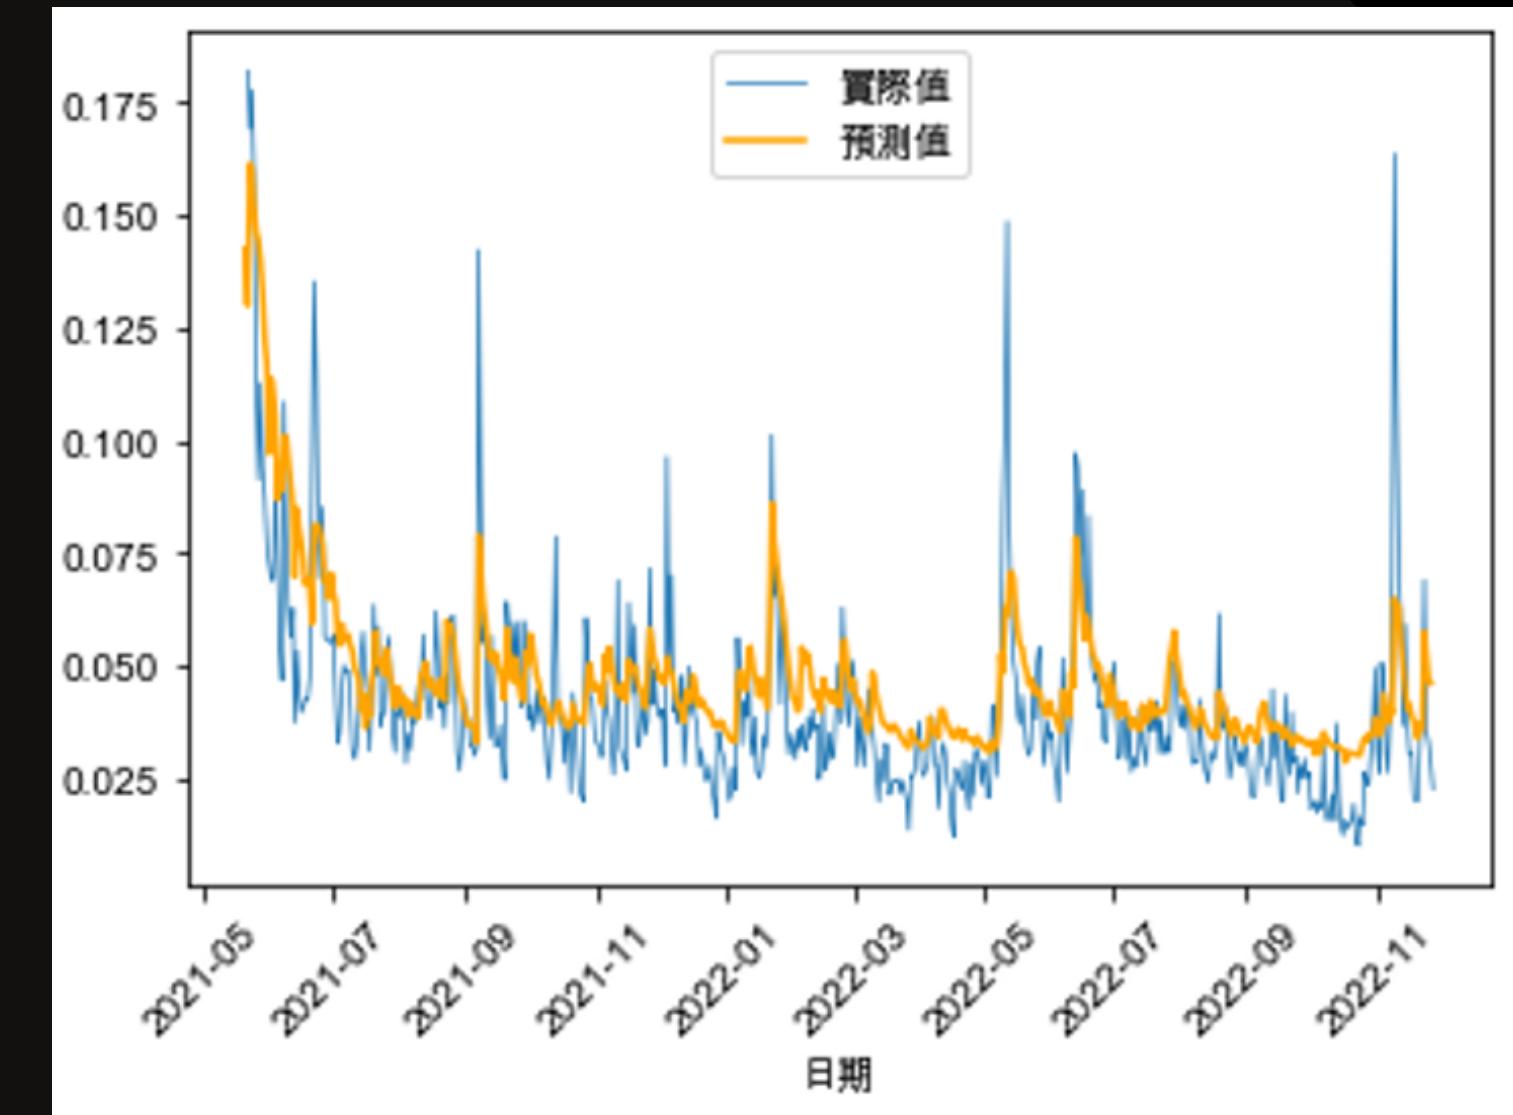


ETH		T+1	T+2	T+3	T+5
ARMA-GARCH_3min	MAE	0.0132	0.0144	0.015	0.0157
	RMSE	0.5138	0.5511	0.5709	0.5919
	MAPE	31.3068	34.143	35.7251	37.4891
ARMA-GARCH_5min	MAE	0.013	0.015	0.015	0.016
	RMSE	0.552	0.588	0.607	0.627
	MAPE	31.641	34.469	36.029	37.814
ARMA-GARCH_15min	MAE	0.014	0.015	0.016	0.016
	RMSE	0.485	0.526	0.546	0.569
	MAPE	35.095	38.056	39.824	41.613

幣安幣 (BNB)
3分鐘為區間
下一期 ($t+1$) 預測

$$y_t = 0.0051 + 0.0742 y_{t-1}$$

$$\sigma_t^2 = 1.0215 * 10^{-4} + 0.1998 u_{t-1}^2 + 0.7802 \sigma_{t-1}^2$$



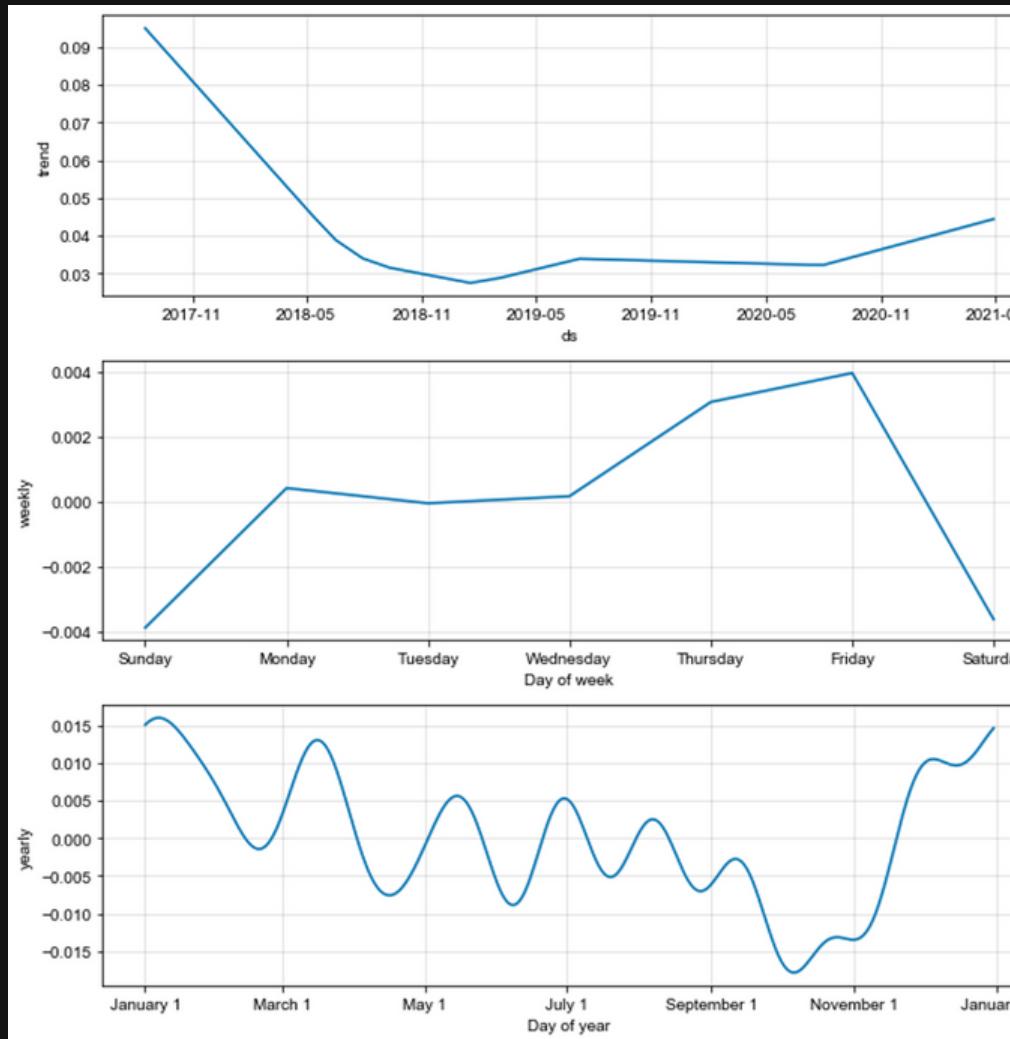
BNB		T+1	T+2	T+3	T+5
ARMA-GARCH_3min	MAE	0.0127	0.0137	0.0152	0.0166
	RMSE	0.4148	0.4499	0.4769	0.5013
	MAPE	35.4406	37.5265	43.4184	48.7153
ARMA-GARCH_5min	MAE	0.0131	0.014	0.0156	0.0169
	RMSE	0.4405	0.4724	0.4988	0.5204
	MAPE	36.6142	38.7847	44.6785	50.0592
ARMA-GARCH_15min	MAE	0.0138	0.0147	0.0163	0.0176
	RMSE	0.4501	0.4827	0.509	0.535
	MAPE	40.3644	42.6148	48.6657	54.2861

序列分解

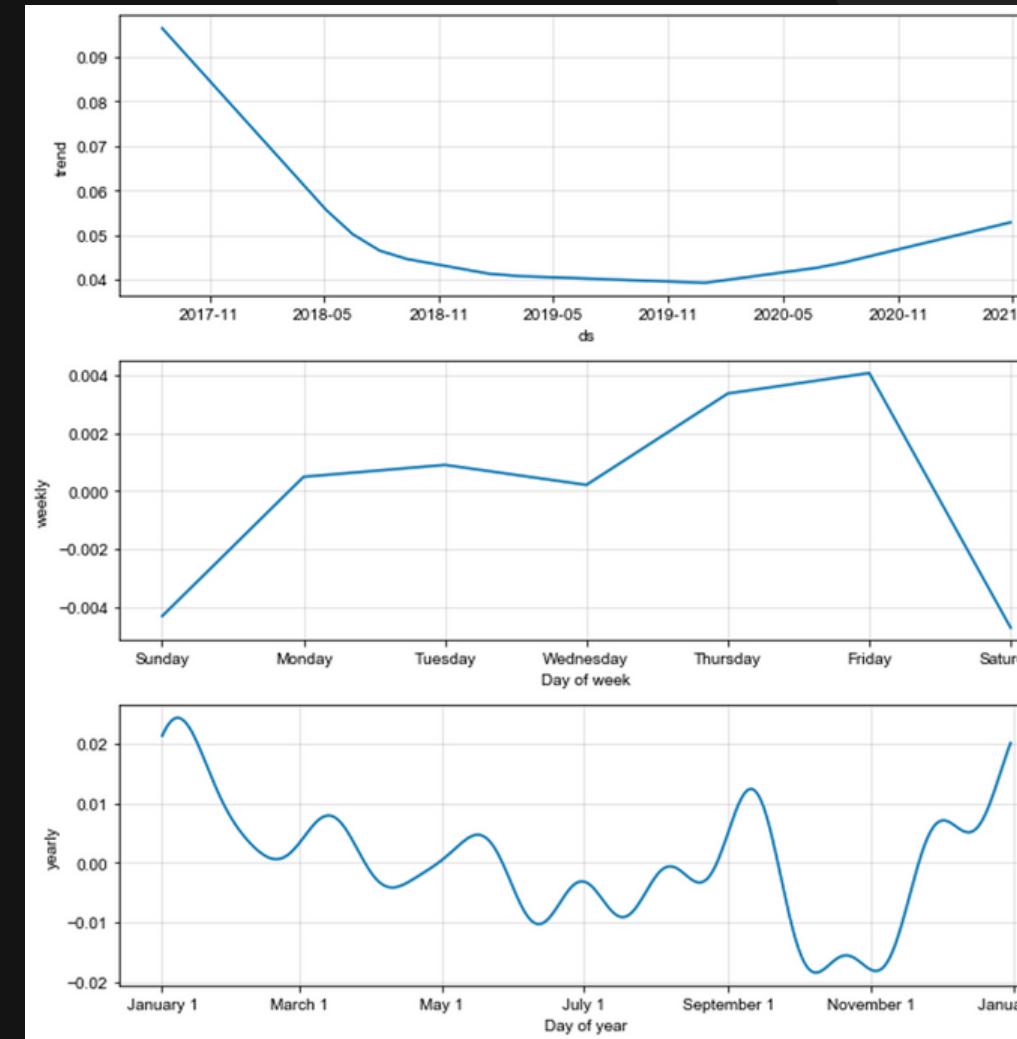
Time-series Decomposition



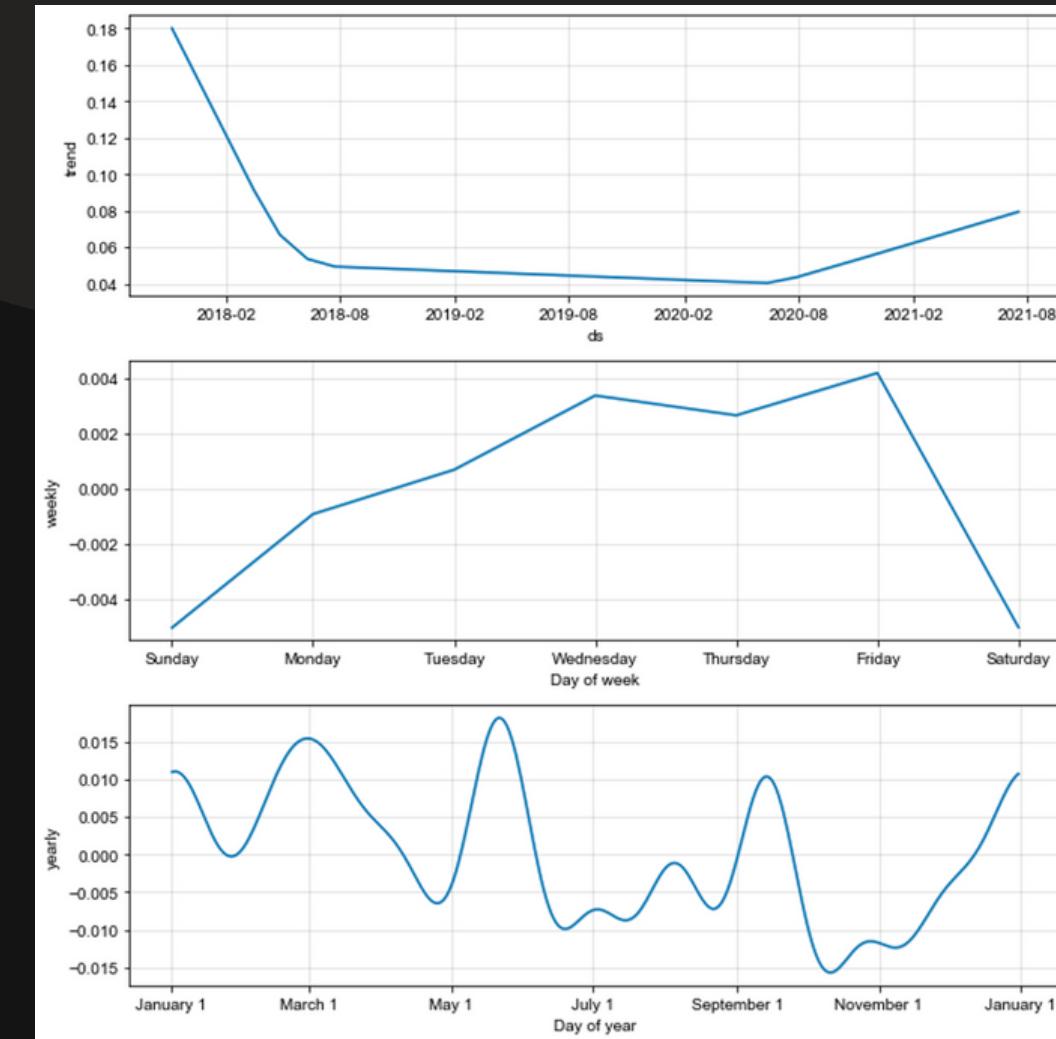
比特幣 (BTC)



以太幣 (ETH)



幣安幣 (BNB)



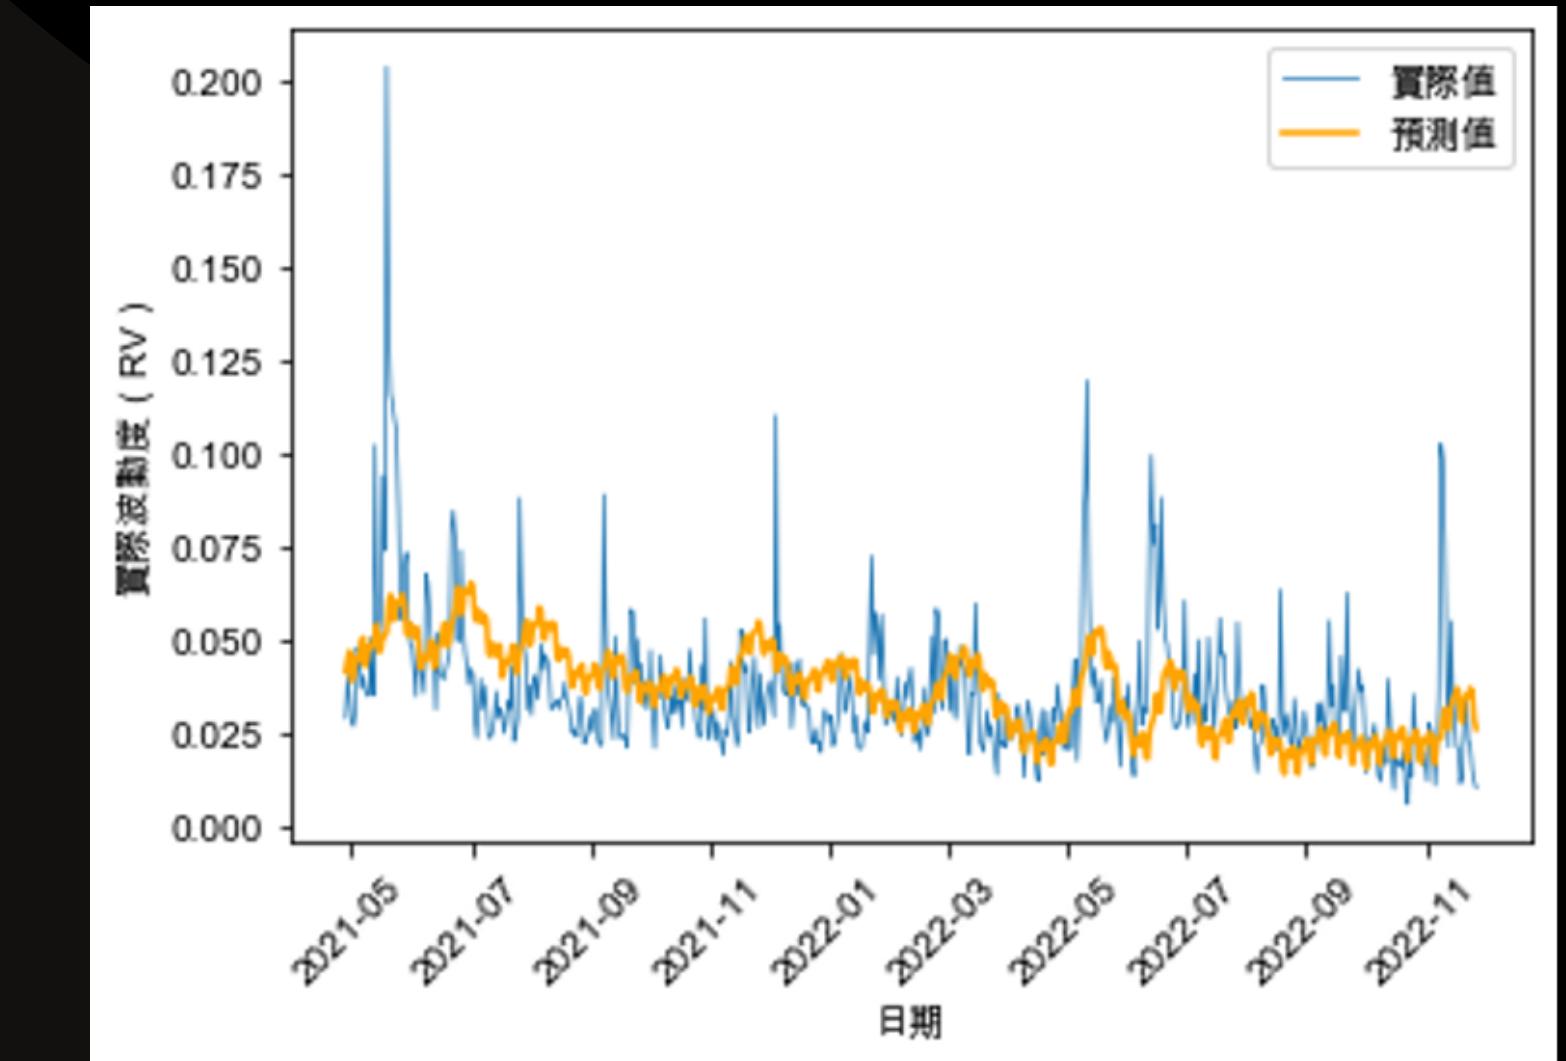
比特幣 (BTC)

3分鐘為區間

下一期 ($t+1$) 預測

$$g(t) = (-0.9417 + (RV_{1349 \times 1})^T * 4.2252 * 10^{-8}) t + (0.3313 + (RV_{1349 \times 1})^T)$$

$$s(t) = X(t) * 0.0166$$



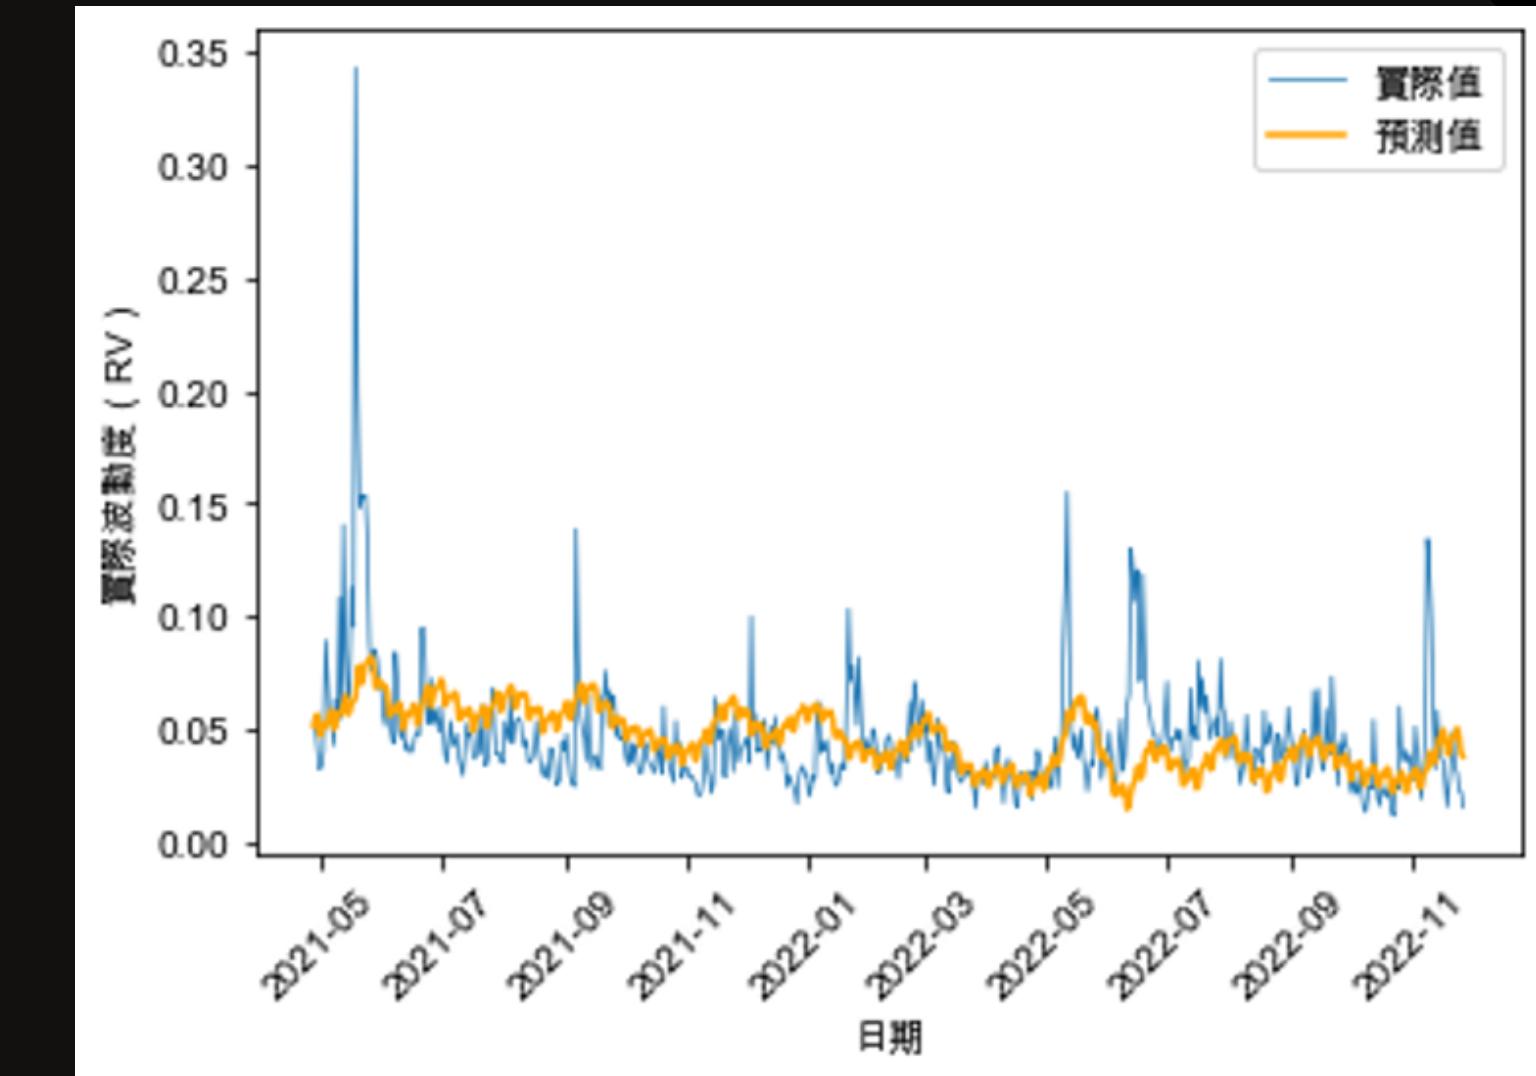
BTC		T+1	T+2	T+3	T+5
Prophet_3min	MAE	0.0120	0.0120	0.0120	0.0130
	RMSE	0.4180	0.4250	0.4310	0.4400
	MAPE	34.2480	34.8720	35.5350	36.4350
Prophet_5min	MAE	0.0120	0.0130	0.0130	0.0170
	RMSE	0.4540	0.4610	0.4670	0.6750
	MAPE	35.4720	36.1770	36.8550	37.8870
Prophet_15min	MAE	0.012	0.012	0.012	0.012
	RMSE	0.412	0.419	0.425	0.433
	MAPE	35.778	36.379	36.908	37.895

以太幣 (ETH)

3分鐘為區間
下一期 (t+1) 預測

$$g(t) = (-0.7779 + (RV_{1349 \times 1})^T * -1.5990 * 10^{-8}) t \\ + (0.3197 + (RV_{1349 \times 1})^T)$$

$$s(t) = X(t) * 0.0114$$



ETH		T+1	T+2	T+3	T+5
Prophet_3min	MAE	0.016	0.016	0.016	0.017
	RMSE	0.601	0.612	0.622	0.636
	MAPE	34.421	35.132	35.857	36.921
Prophet_5min	MAE	0.016	0.017	0.017	0.017
	RMSE	0.640	0.651	0.661	0.675
	MAPE	35.116	35.931	36.681	37.887
Prophet_15min	MAE	0.015	0.016	0.016	0.016
	RMSE	0.572	0.583	0.593	0.607
	MAPE	34.863	35.606	36.316	37.236

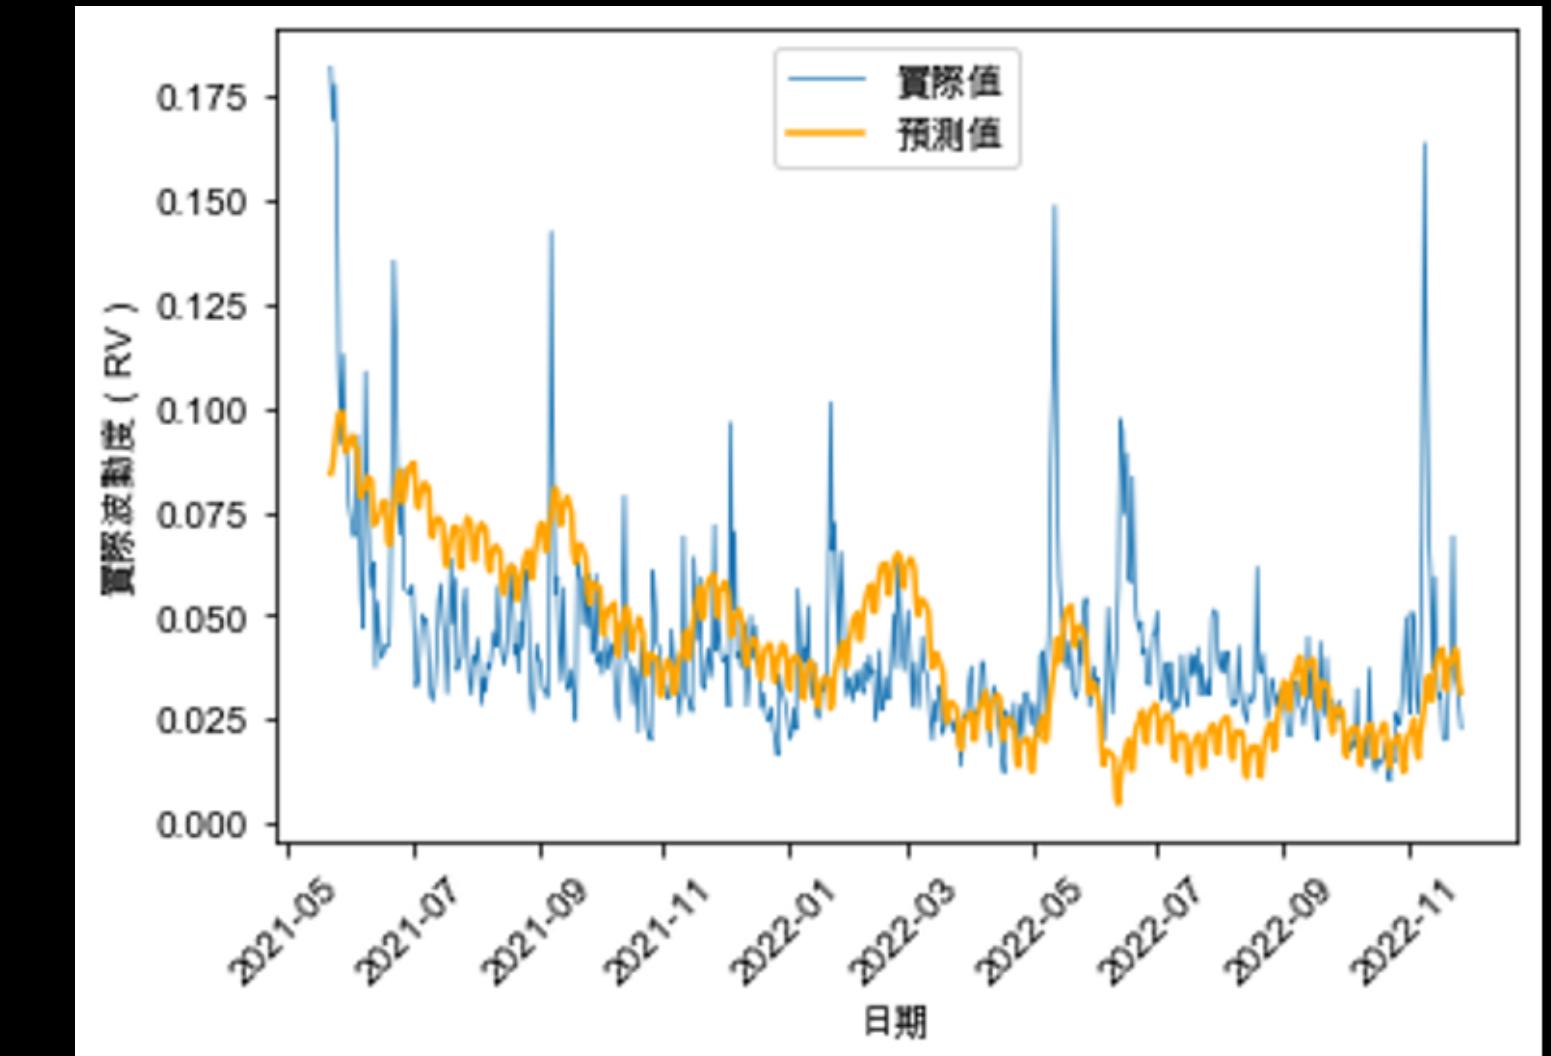
幣安幣 (BNB)

3分鐘為區間

下一期 ($t+1$) 預測

$$g(t) = (-1.2263 + (RV_{1349 \times 1})^T * 2.0747 * 10^{-8}) t + (0.1803 + (RV_{1349 \times 1})^T)$$

$$s(t) = X(t) * 0.0055$$



BNB		T+1	T+2	T+3	T+5
Prophet_3min	MAE	0.0170	0.0170	0.0170	0.0170
	RMSE	0.5420	0.5450	0.5480	0.5530
	MAPE	40.7870	41.7270	42.6110	44.1860
Prophet_5min	MAE	0.0170	0.0180	0.0180	0.0180
	RMSE	0.5720	0.5730	0.5780	0.5810
	MAPE	42.6550	43.6840	44.6560	46.4210
Prophet_15min	MAE	0.0170	0.0170	0.0170	0.0170
	RMSE	0.5520	0.5520	0.5570	0.5610
	MAPE	42.1340	43.0820	43.9800	45.5540

RNN-LSTM 架構

- 基於 Ha Young Kima et.al (2018) 研究方法
- 3層LSTM + 2層連接層
- LSTM神經元個數 (node) : 10、4、2
- 連接層神經元個數 (node) : 5、1 主要進行維度變換，計算損失 (loss)
- 捨棄率 (Dropout rating) : 0.3、0.8、0.8 避免過度擬合 (Overfitting)
- 學習率 (Learning rate) : 0.0001

LSTM	MAE	RMSE	MAPE
BTC_3min			
1 layer	0.0112	0.416	34.1297
2 layers	0.0114	0.4112	35.7987
3 layers	0.0108	0.3981	33.5153
BTC_5min			
1 layer	0.0115	0.4456	34.6482
2 layers	0.0125	0.476	34.5913
3 layers	0.011	0.4255	33.4963
BTC_15min			
1 layer	0.0112	0.409	36.6776
2 layers	0.0137	0.4907	36.082
3 layers	0.011	0.393	36.063

ETH_3min			
1 layer	0.0136	0.5393	31.0159
2 layers	0.0137	0.5143	33.2756
3 layers	0.013	0.525	30.939
ETH_5min			
1 layer	0.014	0.5714	31.7522
2 layers	0.0172	0.6322	41.4797
3 layers	0.014	0.559	30.536
ETH_15min			
1 layer	0.0137	0.5143	33.2756
2 layers	0.0149	0.5648	33.0607
3 layers	0.013	0.504	32.549

BNB_3min			
1 layer	0.0114	0.4298	28.2506
2 layers	0.0108	0.4072	26.8989
3 layers	0.011	0.4116	27.7438
BNB_5min			
1 layer	0.0121	0.4639	30.5632
2 layers	0.0127	0.4431	34.7931
3 layers	0.0116	0.4441	28.9924
BNB_15min			
1 layer	0.0123	0.4563	32.6721
2 layers	0.0121	0.4327	33.9713
3 layers	0.0117	0.4366	31.347

比特幣 (BTC)

3分鐘為區間

下一期 (t+1) 預測

Input gate

$$i_t = \text{sigmoid}(0.0033 RV_t + 0.1967 \overline{RV}_{t-1} - 0.0105)$$

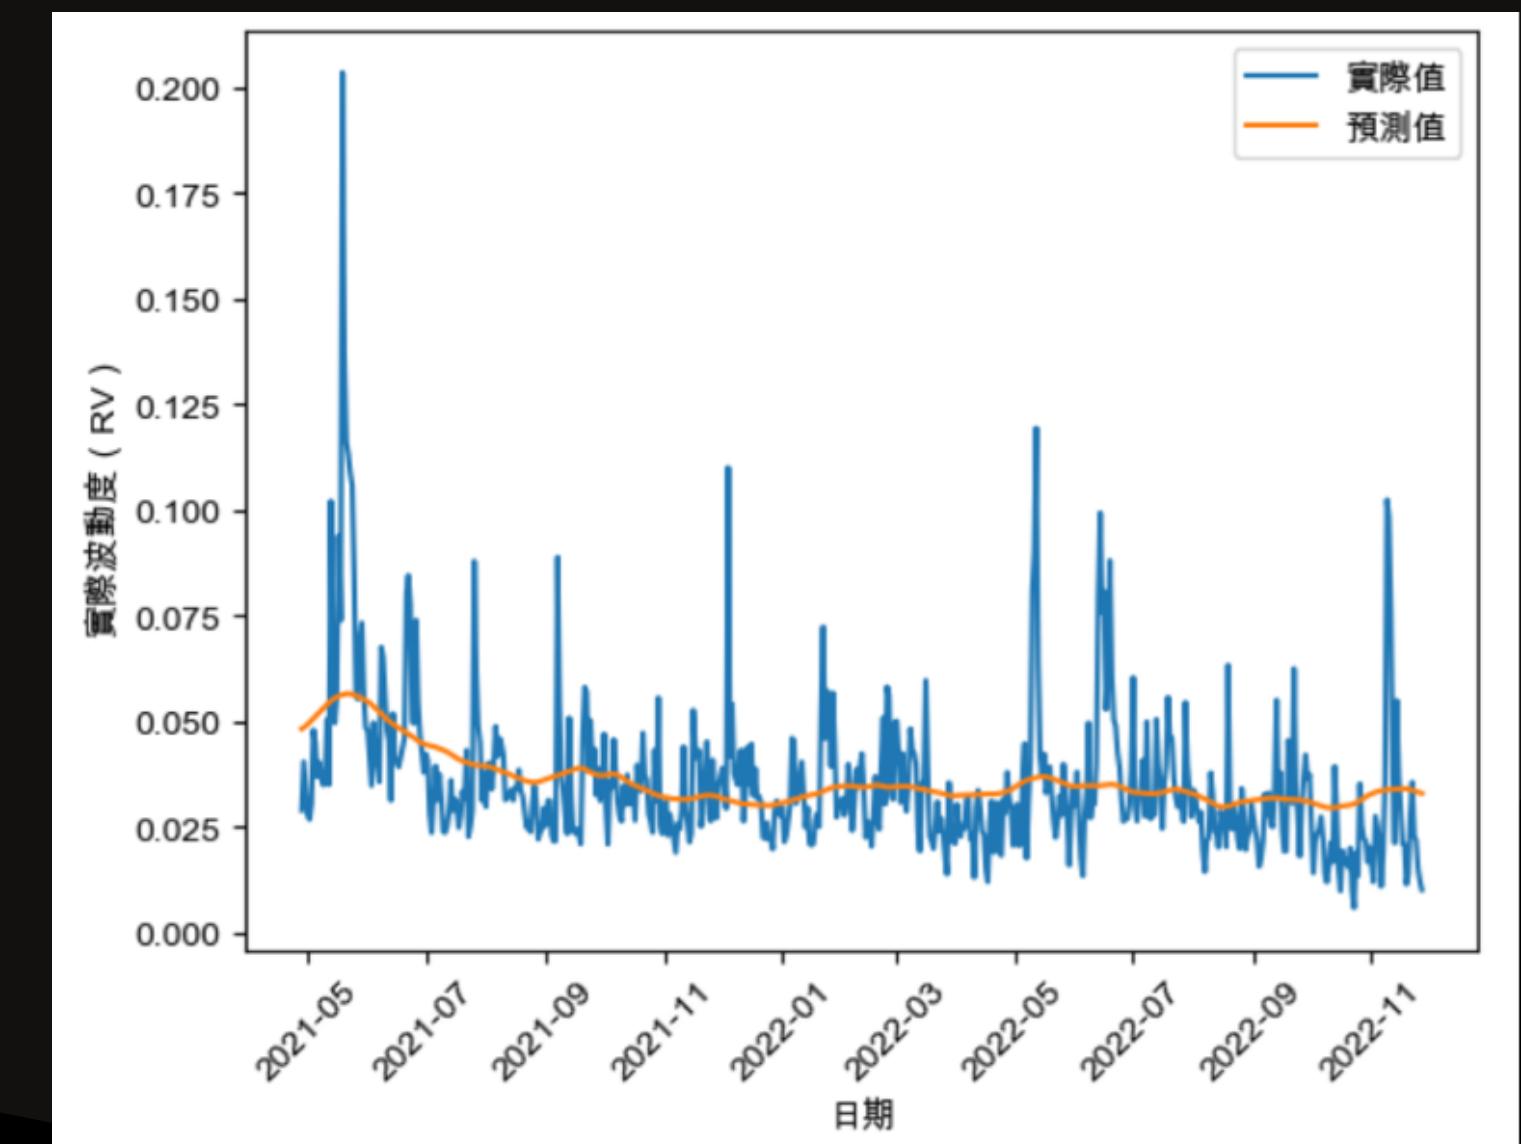
Forget gate

$$g_t = \text{sigmoid}(9.6754 * 10^{-2} * RV_t + 0.2056 \overline{RV}_{t-1} + 0.9893)$$

$$\tilde{C}_t = \text{sigmoid}(0.1612 * RV_t + 0.1746 \overline{RV}_{t-1} - 0.0062)$$

Output gate

$$o_t = \text{sigmoid}(-0.0890 * RV_t + 0.3006 \overline{RV}_{t-1} - 0.0105)$$



BTC		T+1	T+2	T+3	T+5
RNN-LSTM_3min	MAE	0.0108	0.0109	0.0114	0.0124
	RMSE	0.3981	0.4040	0.4312	0.4567
	MAPE	33.5131	33.8687	35.7328	39.5548
RNN-LSTM_5min	MAE	0.0110	0.0113	0.0121	0.0130
	RMSE	0.4255	0.4335	0.4674	0.4903
	MAPE	33.4963	34.4305	37.4334	41.0036
RNN-LSTM_15min	MAE	0.011	0.011	0.012	0.012
	RMSE	0.393	0.400	0.431	0.447
	MAPE	36.063	36.399	39.336	41.713

以太幣 (ETH)

3分鐘為區間

下一期 (t+1) 預測

Input gate

$$i_t = \text{sigmoid}(-0.089 RV_t + 0.0082 \overline{RV}_{t-1} - 0.0064)$$

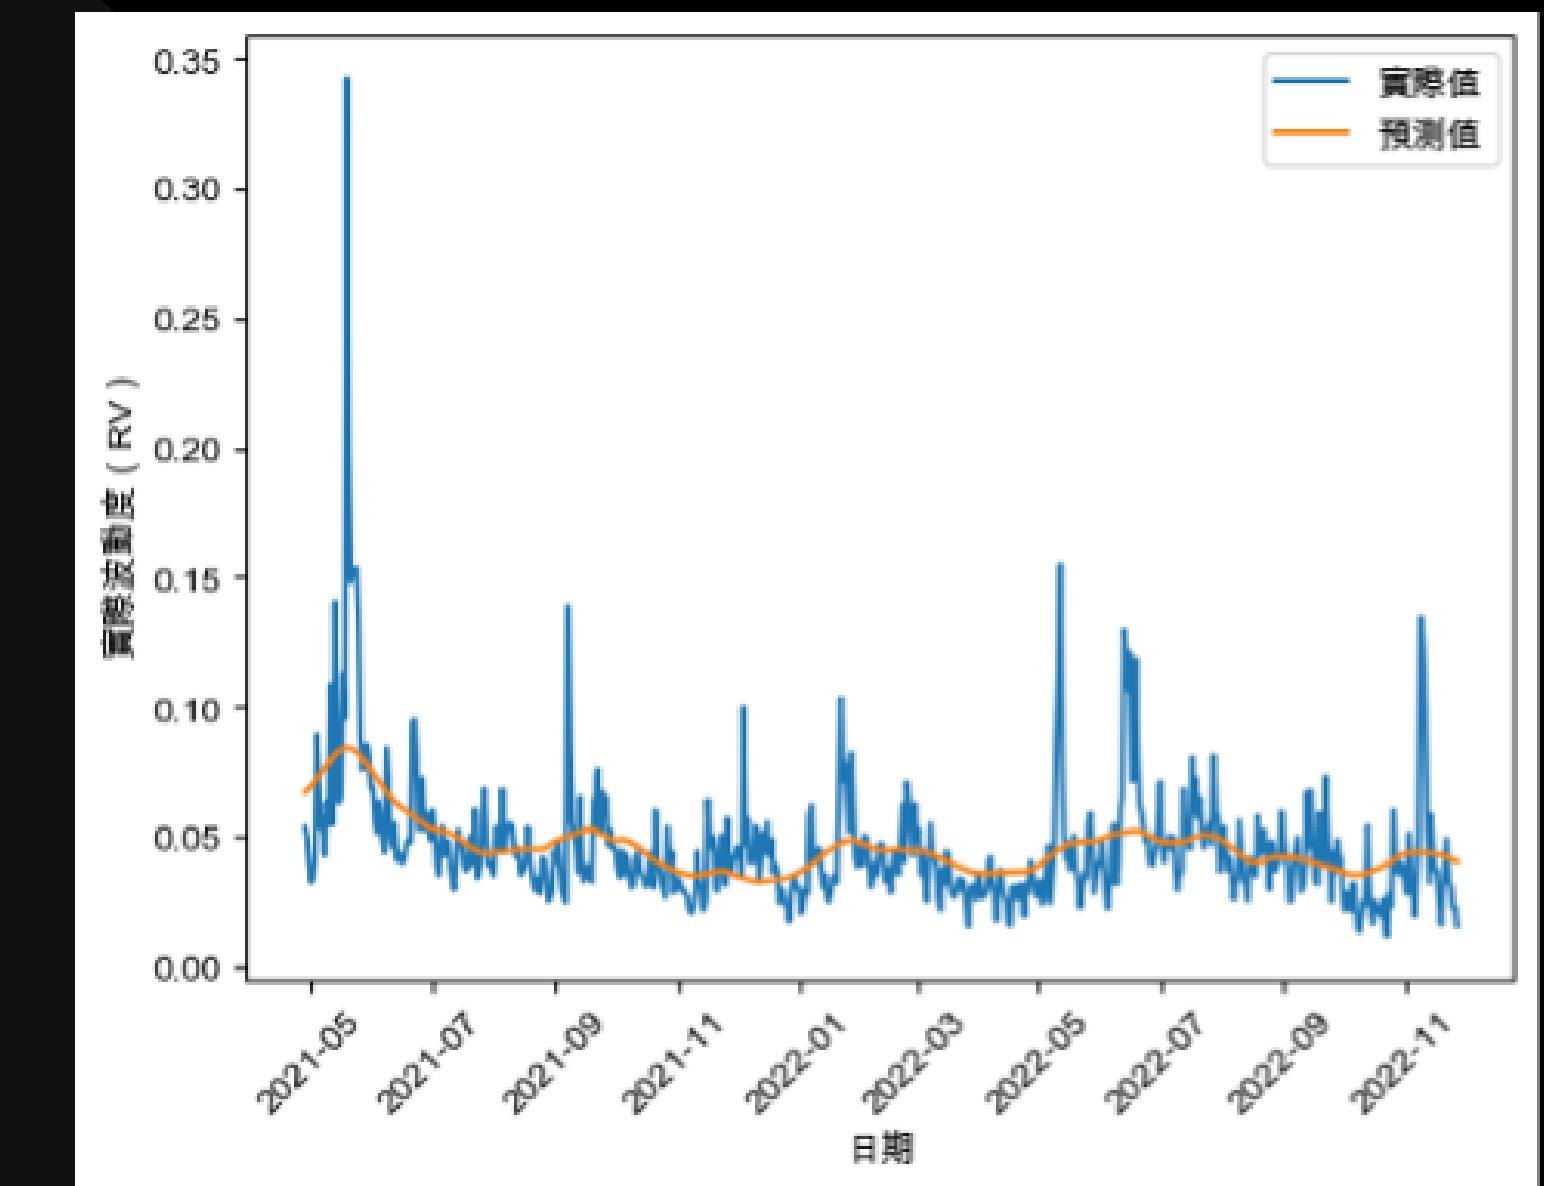
Forget gate

$$g_t = \text{sigmoid}(0.0991 * RV_t + 0.2104 \overline{RV}_{t-1} + 0.9939)$$

$$\tilde{C}_t = \text{sigmoid}(0.1657 * RV_t + 0.1774 \overline{RV}_{t-1} - 0.0063)$$

Output gate

$$o_t = \text{sigmoid}(-0.0883 * RV_t + 0.3044 \overline{RV}_{t-1} - 0.0064)$$



ETH	T+1	T+2	T+3	T+5
RNN-LSTM_3min	MAE	0.013	0.013	0.014
	RMSE	0.525	0.538	0.565
	MAPE	30.939	30.991	32.772
RNN-LSTM_5min	MAE	0.014	0.014	0.016
	RMSE	0.559	0.576	0.647
	MAPE	30.536	31.573	37.796
RNN-LSTM_15min	MAE	0.013	0.014	0.015
	RMSE	0.504	0.518	0.562
	MAPE	32.549	33.446	36.674

幣安幣 (BNB)

3分鐘為區間

下一期 (t+1) 預測

Input gate

$$i_t = \text{sigmoid}(0.1968 RV_t + 0.0041 \overline{RV}_{t-1} - 0.0091)$$

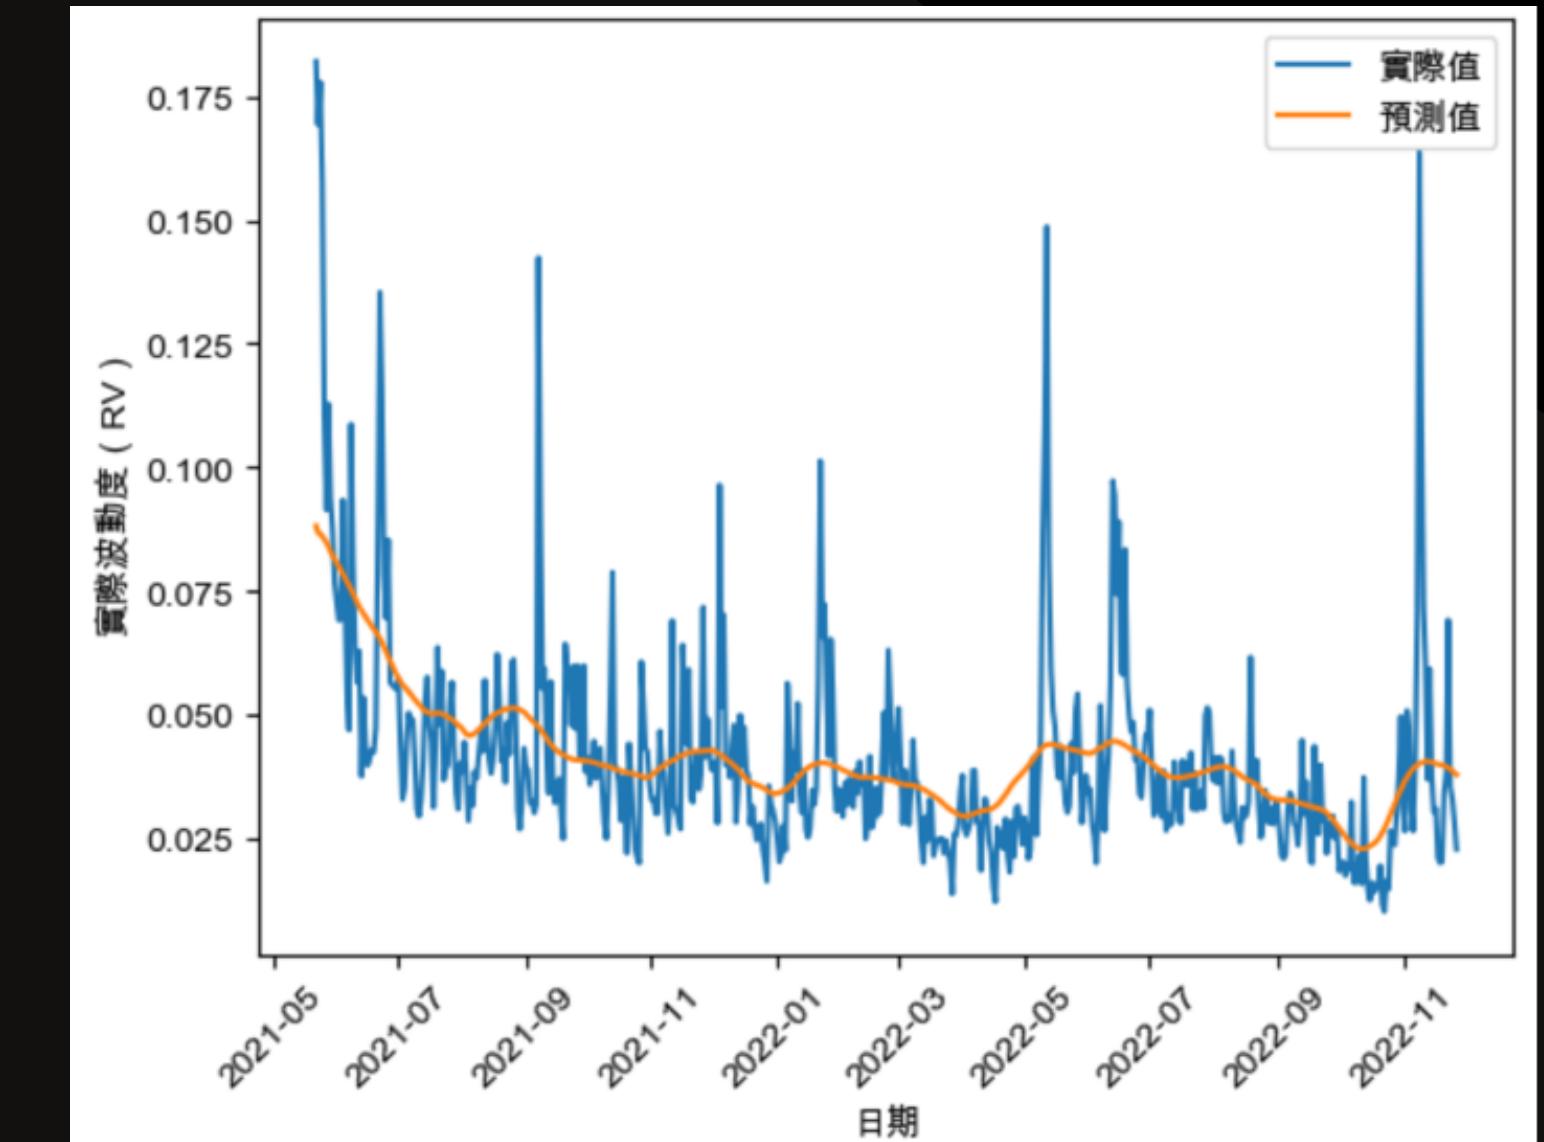
Forget gate

$$g_t = \text{sigmoid}(0.0975 * RV_t + 0.2075 \overline{RV}_{t-1} + 0.9913)$$

$$\tilde{C}_t = \text{sigmoid}(0.1632 * RV_t + 0.1745 \overline{RV}_{t-1} - 7.1100 * 10^{-3})$$

Output gate

$$o_t = \text{sigmoid}(-8.9949 * 10^{-2} * RV_t + 0.3006 \overline{RV}_{t-1} - 0.0091)$$



BNB		T+1	T+2	T+3	T+5
RNN-LSTM_3min	MAE	0.0110	0.0110	0.0119	0.0137
	RMSE	0.4116	0.4089	0.4343	0.4626
	MAPE	27.7438	28.4159	31.5409	39.7572
RNN-LSTM_5min	MAE	0.0116	0.0118	0.0127	0.0143
	RMSE	0.4441	0.4381	0.4304	0.4919
	MAPE	28.9924	30.6622	37.6908	41.5207
RNN-LSTM_15min	MAE	0.0117	0.0118	0.0122	0.0143
	RMSE	0.4366	0.4318	0.4442	0.4792
	MAPE	31.3470	32.1653	33.5821	43.3087

	BTC	T+1	T+2	T+3	T+5	ETH	T+1	T+2	T+3	T+5	BNB	T+1	T+2	T+3	T+5
以3分鐘為區間															
ARMA-GARCH	MAE	0.0101	0.0109	0.0113	0.0119	MAE	0.0132	0.0144	0.015	0.0157	MAE	0.0127	0.0137	0.0152	0.0166
	RMSE	0.3714	0.3976	0.412	0.4249	RMSE	0.5138	0.5511	0.5709	0.5919	RMSE	0.4148	0.4499	0.4769	0.5013
	MAPE	31.6999	34.0795	35.5684	37.4741	MAPE	31.3068	34.143	35.7251	37.4891	MAPE	35.4406	37.5265	43.4184	48.7153
Prophet	MAE	0.012	0.012	0.012	0.013	MAE	0.016	0.016	0.016	0.017	MAE	0.017	0.017	0.017	0.017
	RMSE	0.418	0.425	0.431	0.44	RMSE	0.601	0.612	0.622	0.636	RMSE	0.542	0.545	0.548	0.553
	MAPE	34.248	34.872	35.535	36.435	MAPE	34.421	35.132	35.857	36.921	MAPE	40.787	41.727	42.611	44.186
RNN-LSTM	MAE	0.0108	0.0109	0.0114	0.0124	MAE	0.013	0.013	0.014	0.016	MAE	0.011	0.011	0.0119	0.0137
	RMSE	0.3981	0.404	0.4312	0.4567	RMSE	0.525	0.538	0.565	0.63	RMSE	0.4116	0.4089	0.4343	0.4626
	MAPE	33.5131	33.8687	35.7328	39.5548	MAPE	30.939	30.991	32.772	38.647	MAPE	27.7438	28.4159	31.5409	39.7572
以5分鐘為區間															
ARMA-GARCH	MAE	0.0105	0.0113	0.0118	0.0123	MAE	0.013	0.015	0.015	0.016	MAE	0.0131	0.014	0.0156	0.0169
	RMSE	0.4056	0.43	0.4449	0.4571	RMSE	0.552	0.588	0.607	0.627	RMSE	0.4405	0.4724	0.4988	0.5204
	MAPE	32.6351	35.1305	36.5063	38.3777	MAPE	31.641	34.469	36.029	37.814	MAPE	36.6142	38.7847	44.6785	50.0592
Prophet	MAE	0.012	0.013	0.013	0.017	MAE	0.016	0.017	0.017	0.017	MAE	0.017	0.018	0.018	0.018
	RMSE	0.454	0.461	0.467	0.675	RMSE	0.64	0.651	0.661	0.675	RMSE	0.572	0.573	0.578	0.581
	MAPE	35.472	36.177	36.855	37.887	MAPE	35.116	35.931	36.681	37.887	MAPE	42.655	43.684	44.656	46.421
RNN-LSTM	MAE	0.011	0.0113	0.0121	0.013	MAE	0.014	0.014	0.016	0.017	MAE	0.0116	0.0118	0.0127	0.0143
	RMSE	0.4255	0.4335	0.4674	0.4903	RMSE	0.559	0.576	0.647	0.671	RMSE	0.4441	0.4381	0.4304	0.4919
	MAPE	33.4963	34.4305	37.4334	41.0036	MAPE	30.536	31.573	37.796	39.885	MAPE	28.9924	30.6622	37.6908	41.5207
以15分鐘為區間															
ARMA-GARCH	MAE	0.011	0.012	0.012	0.012	MAE	0.014	0.015	0.016	0.016	MAE	0.0138	0.0147	0.0163	0.0176
	RMSE	0.37	0.396	0.409	0.422	RMSE	0.485	0.526	0.546	0.569	RMSE	0.4501	0.4827	0.509	0.535
	MAPE	36.824	39.456	40.8	42.613	MAPE	35.095	38.056	39.824	41.613	MAPE	40.3644	42.6148	48.6657	54.2861
Prophet	MAE	0.012	0.012	0.012	0.012	MAE	0.015	0.016	0.016	0.016	MAE	0.017	0.017	0.017	0.017
	RMSE	0.412	0.419	0.425	0.433	RMSE	0.572	0.583	0.593	0.607	RMSE	0.552	0.552	0.557	0.561
	MAPE	35.778	36.379	36.908	37.895	MAPE	34.863	35.606	36.316	37.236	MAPE	42.134	43.082	43.98	45.554
RNN-LSTM	MAE	0.011	0.011	0.012	0.012	MAE	0.013	0.014	0.015	0.016	MAE	0.0117	0.0118	0.0122	0.0143
	RMSE	0.393	0.4	0.431	0.447	RMSE	0.504	0.518	0.562	0.603	RMSE	0.4366	0.4318	0.4442	0.4792
	MAPE	36.063	36.399	39.336	41.713	MAPE	32.549	33.446	36.674	40.81	MAPE	31.347	32.1653	33.5821	43.3087

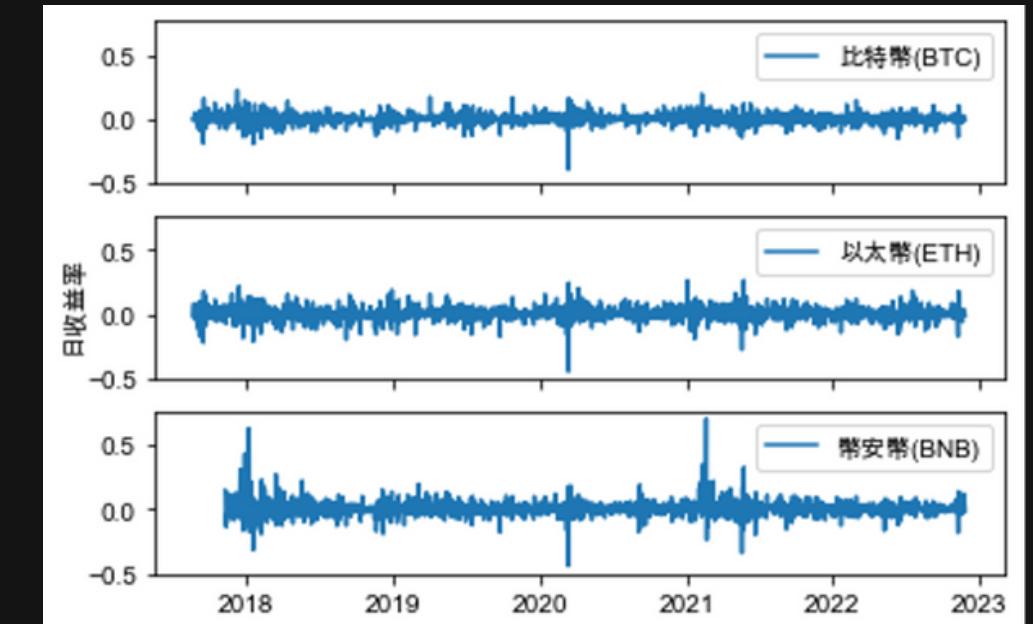
註：粗體表示同組比較誤差值最小



結論

總體而言：

- RNN-LSTM模型表現較好
- Prophet模型表現最差
模型沒有捕捉到節日效果



未來研究方向

增加其他變量，
如總體經濟指標、成交量等

Thank You!
